

- ☒ **Наличие эффекта подтвердило потенциал идеи, поэтому сразу применять по всем городам не будем, но можем провести эксперимент в других городах.**

Задание 2: Основной показатель в статистике

Что такое p-value в статистическом тестировании? Выберите одно верное утверждение:

- ☐ Вероятность, что нулевая гипотеза верна.
- ☒ **Вероятность наблюдения такого или более экстремального результата при условии, что нулевая гипотеза верна.**
- ☐ Значение уровня значимости, при котором отвергается нулевая гипотеза.
- ☐ Среднее значение выборки.

Задание 3: Параметрический тест

Вам необходимо провести аб-тестирование, целевая метрика - среднее число уникальных покупок на пользователя. Размер выборки велик (более 5 млн наблюдений в группах теста и контроля), значительные выбросы в выборках отсутствуют.

Можем ли мы применить t-критерий Стьюдента для проверки гипотезы о равенстве средних в тестовой и контрольной группах при условии, что распределение уникальных покупок является логнормальным?

Ответ: Нет, нельзя применять t-критерий Стьюдента напрямую

Причины:

-Т-критерий Стьюдента предполагает нормальное распределение данных в группах;

-Логнормальное распределение сильно асимметрично (имеет длинный правый хвост), это нарушает предположение о нормальности остатков;

Проблемы с логнормальным распределением:

-Среднее значение в логнормальном распределении смещено вправо

-Т-критерий может давать ложные результаты при асимметричных распределениях

-Доверительные интервалы будут некорректными

Что делать вместо этого:

Логарифмическое преобразование данных:

```
python
```

```
# Если данные логнормальны, то их логарифмы распределены нормально
```

```
log_data_test = np.log(test_data)
```

```
log_data_control = np.log(control_data)
```

```
# Затем можно применять t-критерий к логарифмированным данным
```

Непараметрические альтернативы:

U-критерий Манна-Уитни (для независимых выборок)

При больших выборках (>5 млн):

Можно использовать z-тест (центральная предельная теорема гарантирует нормальность выборочных средних)

Почему z-тест может работать:

При $N > 5$ млн:

Распределение выборочного среднего будет приближенно нормальным (ЦПТ)

Стандартные ошибки будут очень малы

Но нужно проверять однородность дисперсий!

Что можно сделать:

Использовать логарифмическое преобразование + t-критерий

Или напрямую применить U-критерий Манна-Уитни

Или использовать z-тест с проверкой гомогенности дисперсий

Важно: Даже при больших выборках форма распределения исходных данных влияет на мощность теста и интерпретацию результатов!

Блок 5: ML Base

Задание 1: Пони тоже кони

Вас просят разработать модель, классифицирующую лошадок и пони. Вместо разработки вы нашли на GitHub две интересные модели и после прогона на ваших данных одна из них показала ROC-AUC=0.7, а другая ROC-AUC=0.1. Какую модель вы возьмете для дальнейшей работы и что будете с ней делать?

Ответ написать развернутый, но кратко, например: "первую, отниму от метрики 0.1 для корректировки точности": **Выбираем первую модель с некоторыми предсказательными способностями (случайное угадывание = 0,5). Диагностика текущего состояния:**

Посмотреть confusion matrix

Проверить precision, recall, F1-score

Проанализировать ошибки: какие примеры классифицируются неправильно

Исследование данных:

Проверить баланс классов (лошади vs пони)

Анализ качества и репрезентативности данных

Выявление потенциальных проблем в данных

**Улучшение модели (ROC-AUC = 0.7 → целевой 0.85+):
Подбор гиперпараметров, + другие алгоритмы**

Задание 2: Ручной счёт ROC_AUC

Классификатор выдал следующие прогнозируемые метки класса и вероятности принадлежности к классу "1". На основе полученных данных рассчитайте метрику ROC_AUC. Тезисно описать ход решения.

Ответ округлить до сотых, например: 4,12

Истинная метка класса	Порог классификации (0.6)	Оценка вероятности
1	1	0.95
0	1	0.9
1	1	0.85
0	1	0.8
1	1	0.75
1	1	0.7
1	1	0.65
1	1	0.6
0	0	0.55
0	0	0.5
0	0	0.45
1	0	0.4
0	0	0.35
0	0	0.3
0	0	0.25

Подсчет:

Объектов класса 1: 7 (индексы: 0, 2, 4, 5, 6, 7, 11)

Объектов класса 0: 8 (индексы: 1, 3, 8, 9, 10, 12, 13, 14)

Всего возможных пар: $7 \times 8 = 56$

Для каждого объекта класса 1 считаем, сколько объектов класса 0 имеют меньшую вероятность:

Объект 1 (вероятность 0.95, класс 1):

Все 8 объектов класса 0 имеют меньшую вероятность ✓

Объект 3 (вероятность 0.85, класс 1):

Объекты класса 0 с меньшей вероятностью: все, кроме первого (0.9) → 7 ✓

Объект 5 (вероятность 0.75, класс 1):

Объекты класса 0 с меньшей вероятностью: все, кроме первых двух (0.9, 0.8) → 6 ✓

Объект 6 (вероятность 0.7, класс 1):

Объекты класса 0 с меньшей вероятностью: кроме (0.9, 0.8) → 6 ✓

Объект 7 (вероятность 0.65, класс 1):

Объекты класса 0 с меньшей вероятностью: кроме (0.9, 0.8) → 6 ✓

Объект 8 (вероятность 0.6, класс 1):

Объекты класса 0 с меньшей вероятностью: кроме (0.9, 0.8, 0.55) → 5 ✓

Объект 12 (вероятность 0.4, класс 1):

Объекты класса 0 с меньшей вероятностью: кроме (0.9, 0.8, 0.55, 0.5, 0.45, 0.35, 0.3, 0.25) → 0

Сумма правильных пар: $8 + 7 + 6 + 6 + 6 + 5 + 0 = 38$

ROC-AUC = 38 / 56 ≈ 0.68

Задание 3: Ручной счёт корреляции

Рассчитайте линейную корреляцию Пирсона, на основе данных.

Какой вывод можно сделать на основе полученного результата? Можно ли утверждать, что существует причинно-следственная связь между количеством чашек кофе, выпитых студентами в течение экзаменационного дня, и их итоговым баллом за экзамен?

Ответ округлить до сотых, например: 4,12

Число выпитых чашек кофе	Балл за экзамен
1	85
1	88
2	79
2	81
2	84
2	65
3	67
3	58
3	76
4	49

1. Данные:

X (чашки кофе): [1, 1, 2, 2, 2, 2, 3, 3, 3, 4]

Y (баллы): [85, 88, 79, 81, 84, 65, 67, 58, 76, 49]

n = 10

2. Вычисление сумм:

$$\Sigma X = 1+1+2+2+2+2+3+3+3+4 = 23$$

$$\Sigma Y = 85+88+79+81+84+65+67+58+76+49 = 732$$

$$\Sigma X^2 = 1+1+4+4+4+4+9+9+9+16 = 61$$

$$\Sigma Y^2 = 7225+7744+6241+6561+7056+4225+4489+3364+5776+2401 = 55082$$

$$\Sigma XY = (1 \times 85) + (1 \times 88) + (2 \times 79) + (2 \times 81) + (2 \times 84) + (2 \times 65) + (3 \times 67) + (3 \times 58) + (3 \times 76) + (4 \times 49)$$

$$= 85 + 88 + 158 + 162 + 168 + 130 + 201 + 174 + 228 + 196 = 1590$$

Числитель:

$$10 \times 1590 - 23 \times 732 = 15900 - 16836 = -936$$

Знаменатель:

$$\text{Часть 1: } n\Sigma X^2 - (\Sigma X)^2 = 10 \times 61 - 23^2 = 610 - 529 = 81$$

$$\text{Часть 2: } n\Sigma Y^2 - (\Sigma Y)^2 = 10 \times 55082 - 732^2 = 550820 - 535824 = 14996$$

$$R = -936 / \sqrt{1,214,676} = \mathbf{-0.85}$$

Корреляция отрицательная, сильная, вывод: чем больше выпито чашек кофе, - тем хуже результат на экзамене.

Рекомендации по подготовке к собеседованию в случае успешного решения тестового задания

- Знать основы теории вероятностей;
- Знать основы математической статистики;
- Иметь практический навык реализации базовых запросов на SQL;
- Знать основы реализации алгоритмических задач на Python и оценки сложности алгоритмов;
- Приветствуется коммерческий опыт и знания в области планирования и проведения АБ-тестов.